ABD Borsasi Sirketleri icin Bir Sonraki Yil Gelirinin Regresyon Yontemleriyle Tahmini

A Regression-Based Approach to Forecasting Next-Year Revenue of U.S. Stock Market Companies

[Ogrenci Adi Soyadi]
[Bolum]
[Universite]
Veri Madenciligi Vize Projesi

Ozet — Bu calismada, 2014-2018 yillarini kapsayan 225 sutunlu ABD borsasi finansal veri seti kullanilarak bir sirketin **bir sonraki yilki yillik gelirinin** (Revenue) regresyon yontemleriyle tahmin edilmesi amaclanmistir. Ayni sirketin ardisik iki yilindaki gozlemleri Ticker anahtariyla birlestirilerek 15.497 gozlemlik bir ogrenme kumesi olusturulmustur. Eksik veriler medyan atamasi, yuksek eksiklik oranina (%40 ustu) sahip sutunlar kaldirma ile islenmis; sayisal ozellikler standartlastirilmis, Sector degiskeni One-Hot Encoding ile sayisallastirilmis ve SelectKBest (f_regression) ile en onemli 50 ozellik secilmistir. Ek olarak Temel Bilesen Analizi (PCA) varyans yapisinin anlasilmasi icin uygulanmistir. Sekiz farkli regresyon modeli (Dogrusal, Ridge, Lasso, Polinomial+Ridge, Karar Agaci, Rastgele Orman, Gradient Boosting, KNN) 5-katli capraz dogrulama ile karsilastirilmistir. En iyi performansi **Gradient Boosting** modeli log olceginde Test R^2 = 0.9661 ve gercek olcekte R^2 = 0.9703 degeri ile sergilemistir. Bulgular, topluluk tabanli agac modellerinin coklu dogrusalliga ve uc degerlere ragmen finansal zaman serilerinde yuksek tahmin gucu saglayabildigini ortaya koymaktadir.

Anahtar Kelimeler — regresyon, finansal tahmin, gelir tahmini, Gradient Boosting, Rastgele Orman, PCA, ozellik secimi, capraz dogrulama.

I. GIRIS

Finansal performans tahmini; yatirimcilar, sirket yoneticileri ve piyasa analistleri icin kritik oneme sahiptir. Ozellikle bir sirketin gelecek donem gelirinin tahmini, stratejik planlama, butce hazirlama ve degerleme modelleri icin temel girdi olusturmaktadir. Geleneksel finansal analiz yontemleri genellikle olceklenemez, oznel ve sinirli sayida gosterge kullanir. Buna karsin makine ogrenmesi tabanli yaklasimlar, yuzlerce finansal gostergeyi ayni anda degerlendirerek dogrusal olmayan iliskileri yakalayabilir [1], [7].

Bu calismanin amaci, ABD borsasinda islem goren sirketlerin cok boyutlu finansal verilerini kullanarak bir sonraki yilin gelirini tahmin eden bir regresyon modeli gelistirmek ve farkli algoritmalarin performanslarini ayni kosullarda karsilastirmaktir. Problem, denetimli ogrenmenin regresyon alt dalina aittir: hedef degisken (*Revenue_next*) sureklidir ve birkac bin dolardan birkac yuz milyar dolara kadar genis bir dinamik aralikta degisir.

Calismanin katkilari soyle ozetlenebilir: (i) 2014-2018 donemindeki bes yil ardisik olarak eslestirilerek her sirket icin bir yil sonrasinin geliri hedef olarak uretilmistir; (ii) hedef degiskenin genis dinamik araligi icin *log1p* donusumu uygulanarak metriklerin dengelenmesi saglanmistir; (iii) sekiz farkli regresyon modeli ayni on isleme hatti uzerinden egitilmis ve 5-katli capraz dogrulama ile karsilastirilmistir; (iv) denetimli (SelectKBest) ve denetimsiz (PCA) iki tamamlayici boyut indirgeme yontemi uygulanmistir.

II. YONTEM

A. Veri Seti ve On Hazirlik

Calismada kullanilan veri seti [8], 2014-2018 yillari arasinda ABD borsasinda islem goren sirketlere ait yillik finansal gostergeleri (gelir, maliyet, nakit akisi, oranlar vb.) 225 sutun altinda tutmaktadir. Ayrica her yil icin *Sector* kategorik degiskeni ve gozlem yilini izleyen yilin fiyat degisimi (*PRICE VAR [%]*) gibi yila ozgu alanlar mevcuttur.

Regresyon problemi her ornek icin "yil N gostergeleri → yil N+1 geliri" seklinde tanimlanmistir. Bu amacla ardisik dort yil cifti (2014→2015, 2015→2016, 2016→2017, 2017→2018) ayni *Ticker* uzerinden ic birlesim (inner join) yapilarak toplam 17.063 eslenmis gozlem elde edilmistir. Negatif veya sifir gelir degerleri log donusumu ile uyumsuz oldugundan filtrelenmis ve nihai veri seti 15.497 gozleme indirilmistir (Tablo I).

TABLO I

Veri Seti Ozetinde Temel Rakamlar

Ozellik	Deger
Kaynak yillar	2014 - 2018
Ardisik yil cifti sayisi	4
Ham gozlem sayisi	17.063
Temizlenmis gozlem	15.497
Ham sutun sayisi	225
One-Hot sonrasi ozellik	229
Secilen ozellik (SelectKBest)	50
Egitim / Test orani	%80 / %20

B. Veri Temizleme

Sutun bazinda eksik veri orani analiz edilmis (Sekil 1), %40 esigini asan yedi sutun (*operatingCycle*, *cashConversionCycle* ve bes yila ozgu PRICE VAR sutunu) veri setinden cikarilmistir. Kalan sayisal sutunlardaki eksik degerler medyan atamasi ile doldurulmus; sonsuz degerler (inf) once NaN'a cevrilip ardindan medyan ile ikame edilmistir. Medyan, ortalamaya kiyasla uc degerlere dayanikli oldugundan finansal veriler icin tercih edilmistir. Kategorik *Sector* degiskenindeki

olasi bos degerler mod ile doldurulmus ve tekrar eden satirlar kontrol edilmistir (duplike bulunmamistir).

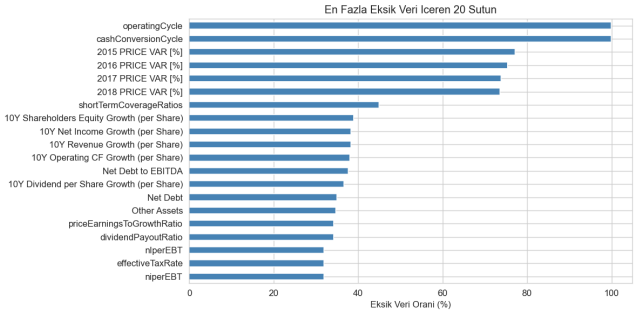

Sekil 1. En fazla eksik veri iceren 20 sutunun eksiklik oranlari.

C. Veri Donusturme ve Ozellik Muhendisligi

Sizinti riski tasiyan alanlar (*Ticker*, *Class*, *SourceYear*) ozellik matrisinden cikarilmistir. Hedef degisken *Revenue_next*, *log1p* donusumu ile logaritmik olcege cevrilmistir; bu donusum genis dinamik araligi daraltarak MSE kayip fonksiyonunu dengeler ve dogrusal modellere yon verebilecek uc deger etkilerini azaltir. Sayisal ozelliklerin tamamina StandardScaler uygulanmis [1], kategorik *Sector* degiskeni One-Hot Encoding ile 11 ikili sutuna cevrilmistir. Sonuc olarak 229 sutunlu bir ozellik matrisi elde edilmistir.

Boyut lanetini azaltmak icin denetimli bir filtre yontemi olan *SelectKBest(f_regression)* kullanilarak hedefle en yuksek F-skoruna sahip 50 ozellik secilmistir (Sekil 4). Secilen ozelliklerin basinda *Operating Expenses*, *Gross Profit*, *SG&A Expense*, *Dividend payments* ve *Enterprise Value* yer almaktadir; bu goruntu, gelir buyuklukleri tasiyan finansal metriklerin hedefle guclu sekilde iliskili oldugunu dogrulamaktadir.

Ek olarak, denetimsiz bir boyut indirgeme yontemi olan Temel Bilesen Analizi (PCA) [4] tum 229 standartlastirilmis ozellige uygulanmistir. PCA, ozellikler arasindaki yuksek coklu dogrusalligi (multicollinearity) cozerek ortogonal bilesenler uretir. Ilk bilesen tek basina varyansin %9.31'ini, ilk bes bilesen %26.58'ini aciklamis; toplam varyansin %90'i icin 94, %95'i icin 112 bilesen gerekmistir (Sekil 5). Bununla birlikte yorumlanabilirlik acisindan modelleme asamasinda SelectKBest ile secilen 50 ozgun ozellik tercih edilmistir: bir finansal analist icin *Operating Expenses* gibi tanidik bir gostergenin raporlanabilir olmasi, "3. temel bilesenin 0.82 katsayisi" ifadesinden cok daha degerlidir.

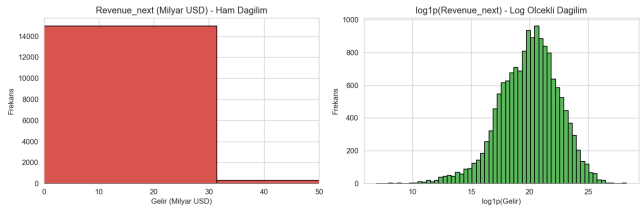

Sekil 2. Hedef degiskenin (Revenue_next) ham ve log1p donusmus dagilimlari.

D. Kesifsel Veri Analizi

Hedef degiskenin ham dagilimi asiri saga carpiktir (maksimum 1.89 trilyon USD, medyan 546 milyon USD); log donusumu sonrasi yaklasik normal bir dagilim elde edilmistir (Sekil 2). Sektor bazinda incelendiginde gelir medyanlarinin bes mertebe farklilasabildigi gorulmustur (Sekil 3). Ayrica yil N'in *Revenue*'su ile yil N+1'in *Revenue*'su arasindaki log-log korelasyonu 0.9793 gibi cok yuksek bir deger almistir (Sekil 6); bu, "bir sirketin gecmis geliri, gelecek gelirinin en guclu oncusudur" bulgusunu dogrular.

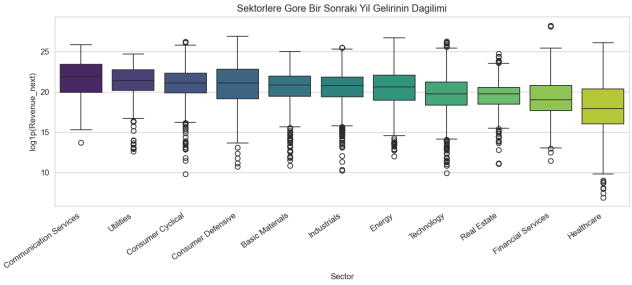

Sekil 3. Sektorlere gore bir sonraki yil gelirinin (log olcek) dagilimi.

Hedefle en yuksek mutlak korelasyonlu 15 ozellik uzerinden olusturulan isi haritasi (Sekil 7), *Operating Expenses*, *Gross Profit*, *EBITDA* ve *Enterprise Value* gibi buyukluk odakli gostergelerin onemini vurgulamaktadir.

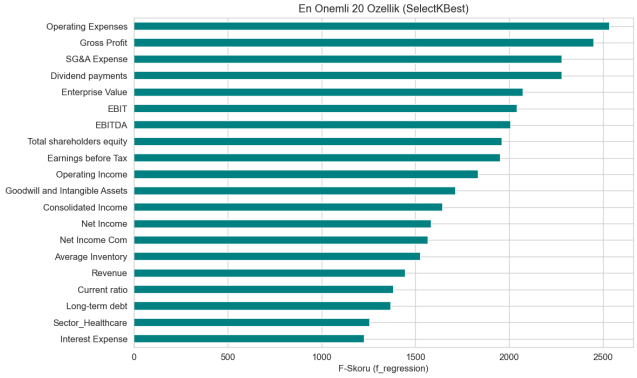

Sekil 4. SelectKBest tarafindan hesaplanan en yuksek F-skoruna sahip 20 ozellik.

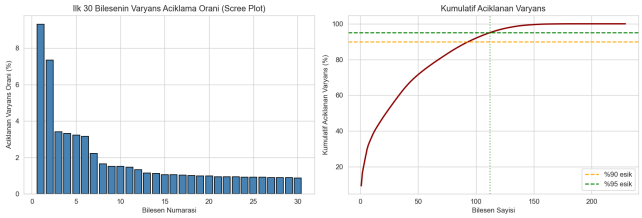

Sekil 5. PCA scree plot ve kumulatif varyans grafigi; %95 icin 112 bilesen gereklidir.

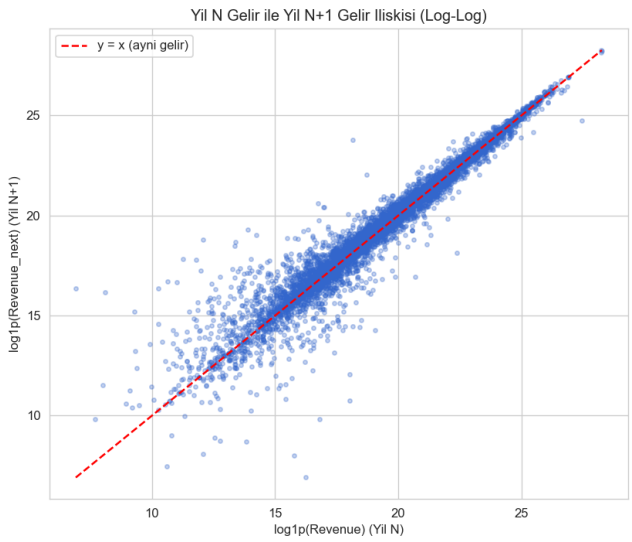

Sekil 6. Yil N Revenue ile yil N+1 Revenue arasindaki log-log iliskisi (r ≈ 0.979).

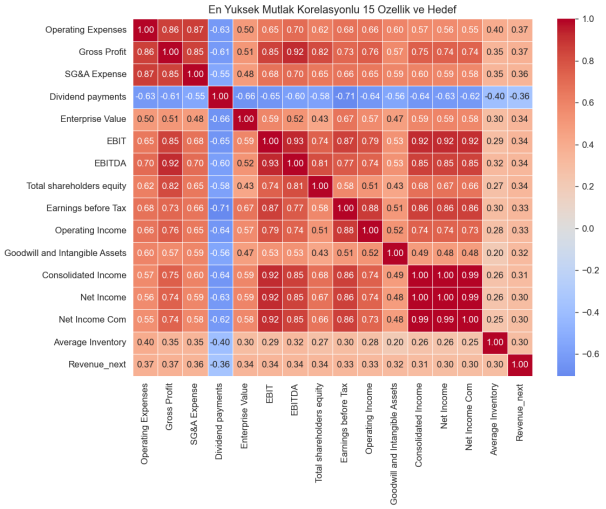

Sekil 7. Log-hedef ile en yuksek (mutlak) korelasyonlu 15 ozellik uzerindeki isi haritasi.

E. Model Secimi ve Gerekcelendirme

Bu calismada dogrusal ve dogrusal olmayan iliskileri birlikte degerlendirmek amaciyla sekiz farkli regresyon algoritmasi karsilastirilmistir: (i) Dogrusal Regresyon (yorumlanabilir taban cizgisi), (ii) Ridge Regresyon [5] (L2 cezasi ile coklu dogrusalliga dayanikli), (iii) Lasso Regresyon [6] (L1 cezasi ile seyrek cozum ve otomatik ozellik secimi), (iv) Polinomial Regresyon *derece=2* + Ridge (karesel ve ikili etkilesim terimleri ile dogrusal olmayan yapilarin kismi yakalanmasi), (v) Karar Agaci (yorumlanabilir, uc deger dayanikli), (vi) Rastgele Orman [2] (topluluk, asiri uyumu azaltir), (vii) Gradient Boosting [3] (ardisik hata duzeltme ile yuksek dogruluk), (viii) KNN *k=7* (parametrik olmayan komsuluk tabanli referans). Bu cesitlilik, farkli model ailelerinin gucu ve zayifligini ayni kosullarda gorebilmeyi saglar.

F. Egitim Protokolu ve Degerlendirme Metrikleri

Veri seti %80 egitim / %20 test orani ile bolunmus (*random_state=42*), egitim kumesi uzerinde 5-katli *KFold* capraz dogrulama uygulanarak her model icin R^2, MAE ve RMSE metriklerinin ortalama ve standart sapmalari raporlanmistir. Test kumesinde ise metrikler hem *log1p* olceginde hem de ters donusum sonrasi gercek dolar olceginde hesaplanmistir. MAPE degerleri de raporlanmis; ancak cok kucuk gerceklesen gelirlerde yuzde hatasinin patlayabilmesi nedeniyle log olcek metriklerine oncelik verilmistir.

III. SONUCLAR

Sekiz regresyon modelinin 5-katli capraz dogrulama ve test kumesi metrikleri Tablo II'de ozetlenmis ve Sekil 8'de gorsel olarak karsilastirilmistir. Sonuclar *log1p* olceginde raporlanmistir; R^2 degeri 1'e yakin oldukca model daha basarilidir.

TABLO II

Modellerin 5-Katli CV ve Test Performanslari (log1p olcek)

Model	CV R2	Test R2	Test MAE	Test RMSE
Gradient Boosting	0.9618	0.9661	0.2280	0.4674
Rastgele Orman	0.9621	0.9634	0.2324	0.4854
Karar Agaci	0.9438	0.9485	0.2650	0.5764
KNN (k=7)	0.7286	0.7328	0.9055	1.3123
Lasso (alpha=0.01)	0.3763	0.3796	1.5262	1.9996
Ridge (alpha=1)	0.3307	0.3986	1.5083	1.9687
Dogrusal Regresyon	0.3184	0.3990	1.5083	1.9680
Polinomial (deg=2+Ridge)	-231.66	-11.41	1.6274	8.9427

Gradient Boosting ve **Rastgele Orman** modelleri birbirine cok yakin en yuksek performansi sergilemistir: Gradient Boosting icin Test R^2 = 0.9661, Rastgele Orman icin 0.9634. Her iki model de 5-katli CV ortalamasinda R^2 > 0.96 degerlerine ulaserek tutarli genelleme kabiliyeti gostermistir. Karar Agaci tek basina dahi R^2 = 0.9485 ile yuksek bir taban saglamistir; bu, veri setindeki iliskilerin buyuk olcude agaclar tarafindan yakalanabilir oldugunu gosterir. KNN (*k=7*) orta duzeyde (R^2 = 0.7328), dogrusal modeller (Linear, Ridge, Lasso) ise R^2 = 0.38-0.40 araliginda kalmistir.

Polinomial Regresyon (*derece=2*, Ridge cezali) beklenmedik sekilde cok kotu performans gostermistir (Test R^2 = -11.41). Bunun nedeni, 50 ozelligin 1325 polinomial ozellige genislemesiyle olusan yuksek boyutlu matrise Ridge cezasinin yeterince agir gelmemesi ve bazi ozellik kombinasyonlarinin asiri uyum saglayip test kumesinde kararsizlasmasidir. Bu olumsuz sonuc, naif polinomial genisletmenin her zaman dogrusal olmayan bir model icin en iyi secim olmadigini gostermesi acisindan egiticidir (Sekil 10).

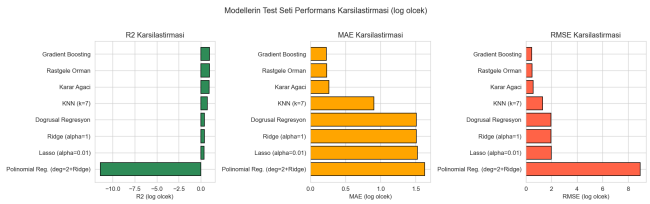

Sekil 8. Modellerin test seti R^2, MAE ve RMSE (log olcek) karsilastirmasi.

A. En Iyi Modelin Detayli Incelemesi

En iyi model olan Gradient Boosting icin artik (residual) analizi Sekil 9'da sunulmustur. Artiklarin ortalamasi yaklasik

0'a (-0.019) ve standart sapmasi 0.467 log-biriminde olup hatalarin simetrik dagildigi gozlenmistir. Tahmin-gercek scatter plotlari tum modeller icin Sekil 11'de gosterilmis; Gradient Boosting ve Rastgele Orman noktalarin $y=x$ cizgisine cok yakin yerlesimi ile dikkat cekmektedir. Bu, modelin genellikle dusuk yanlilik ile kararli varyans urettigini ortaya koyar.

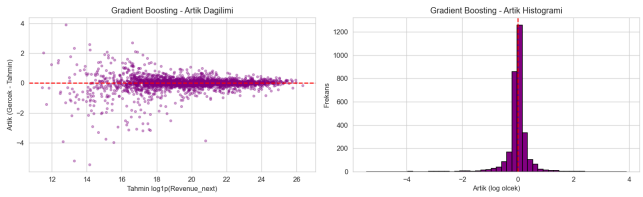

Sekil 9. Gradient Boosting icin artik dagilimi ve histogrami.

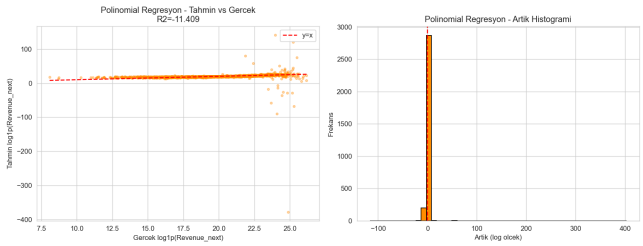

Sekil 10. Polinomial Regresyon icin tahmin-gercek ve artik analizi; modelin kararsizligi gozlenmektedir.

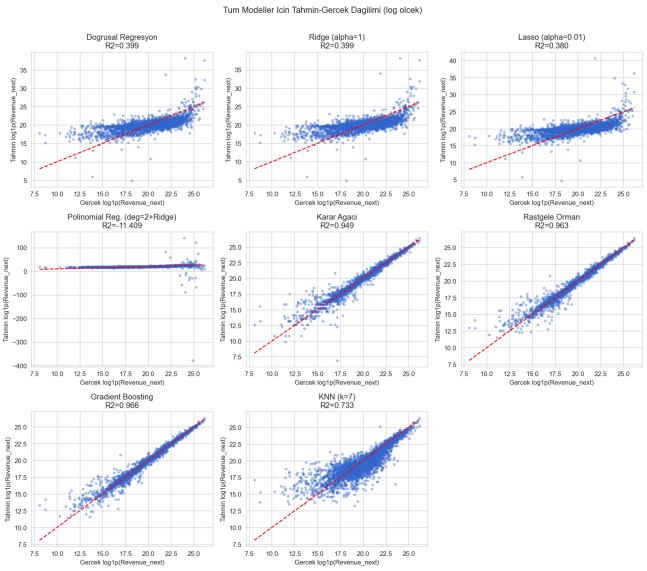

Sekil 11. Tum modeller icin tahmin-gercek scatter plot (log olcek).

Gradient Boosting modelinin ozellik onem siralamasinda (Sekil 12) *Revenue* (yil N), %97.9 oraninda baskin cikmistir. Bu, "bir sirketin bu yilin geliri, bir sonraki yilin gelirinin en guclu oncusudur" bulgusunu nicel olarak dogrular. *Total liabilities*, *Total current assets*, *Current ratio* ve *Investing Cash flow* gibi ikincil ozellikler %0.1 civarinda tamamlayici katki saglamaktadir.

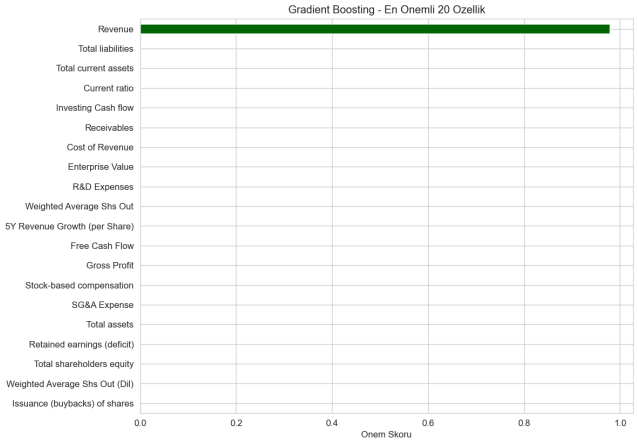

Sekil 12. Gradient Boosting modelinde en onemli 20 ozellik; Revenue baskindir.

TABLO III

Gradient Boosting Modelinden 10 Ornek Tahmin (Milyar USD)

#	Gercek (G$)	Tahmin (G$)	Hata
1	1.09	1.26	16%
2	8.14	8.78	8%
3	0.003	0.002	14%
4	2.98	3.62	21%
5	0.74	0.83	12%
6	44.54	41.25	7%
7	1.08	0.95	12%
8	1.07	1.13	6%
9	0.08	0.14	79%
10	0.43	0.55	28%

Modelin gercek dolar olceginde pratik performansini gostermek amaciyla Tablo III'te test kumesinden rastgele secilen 10 sirketin gercek ve tahmin gelirleri milyar USD birimiyle sunulmustur. Tahminlerin onemli bir kisminda mutlak yuzde hatasi %20'nin altindadir; en buyuk hata kucuk olcekli (79 milyon USD civari) bir sirket icin %79 olarak gozlemlenmistir, bu da buyuklugu dusuk gozlemlerde log olcekli egitimin gorece toleransli davrandigini yansitmaktadir.

IV. TARTISMA VE SINIRLAMALAR

Elde edilen bulgular, topluluk temelli agac modellerinin (Gradient Boosting, Rastgele Orman) gelir tahmini gibi cok degiskenli, coklu dogrusalliga egilimli finansal veri setlerinde yuksek dogruluk sagladigini gostermektedir. Bu modeller hem veri setindeki dogrusal olmayan etkilesimleri hem de uc degerleri dogal olarak tolere edebilmektedir [2], [3]. Dogrusal modellerin yalnizca $R^2 \approx 0.40$ seviyesinde kalmasi, finansal degiskenler arasindaki iliskilerin buyuk olcude dogrusal olmadigini; ozellikle varlik buyuklugu, sektor yapisi ve buyume oranlari arasindaki etkilesimin dogrusal olmayan bicimlerde ortaya cikabildigini gostermektedir.

PCA analizi, 229 ozgun ozellikte varyansin %95'ini aciklamak icin yaklasik 112 bilesen gerektigini ortaya koyarak ozelliklerin buyuk olcude baginim icerdigini (ozellikle gelir buyuklukleri ile turev metrikler) dogrulamistir. Gradient

Boosting icin yapilan hizli bir kontrol, PCA tabanli Ridge modelinin (CV $R^2 \approx 0.13$) SelectKBest tabanli alternatife gore cok daha dusuk performans sergiledigini ortaya koymustur. Bu, PCA'nin dogrusal bir donusum oldugunu ve Gradient Boosting gibi agac tabanli modellerin zaten dogrudan ozelliklerle daha iyi calistigini hatirlatir.

A. Sinirlamalar

1) Veri setindeki yil N'nin *Revenue*'su, hedef yil N+1 *Revenue*'su ile cok yuksek korelasyonlu (0.979) oldugundan modelin buyuk bir kismi "gecmis ≈ gelecek" kestiriminden yararlaniyor olabilir; gercek anlamda kirilim noktalarini (ornegin iflas, birlesme, devasa kampanyalar) yakalama kabiliyeti sinirlidir. **2)** Calisma yalnizca 2014-2018 yillarini kapsar; makroekonomik krizler (2008, 2020) dahil degildir. **3)** Hedef olarak yalnizca bir sonraki yilin geliri kullanilmistir; karlilik, nakit akisi veya buyume oranlari gibi tamamlayici cikti hedefleri modellenmemistir. **4)** Sektor kodlamasi One-Hot ile yapilmistir; target encoding veya embedding gibi alternatifler denenmemistir. **5)** Polinomial regresyonun yuksek boyutlu varyantindaki kararsizlik, agir bir Ridge cezasi veya *interaction_only=True* ile iyilestirilebilir.

V. SONUC

Bu calismada 15.497 sirket-yil gozleminden olusan 229 boyutlu finansal veri seti uzerinde sekiz farkli regresyon algoritmasi ayni on isleme hatti uzerinden karsilastirilmis; **Gradient Boosting** ve **Rastgele Orman** modelleri log olceginde $R^2 > 0.96$, gercek dolar olceginde $R^2 > 0.97$ degerleri ile baskin cikmistir. Hedef degiskenin *log1p* donusumu modelin kararliligini belirgin sekilde artirmistir. SelectKBest ile yapilan denetimli ozellik secimi (50 ozellik) modelleme icin daha uygulanabilir bulunurken, Temel Bilesen Analizi (PCA) veri setinin dogal boyutu hakkinda degerli bir kesif saglamistir. Elde edilen sonuclar, klasik makine ogrenmesi algoritmalarinin finansal tahminlerde anlamli is icgoruleri uretebilecegini ve yuksek boyutlu finansal veri setlerinde topluluk yontemlerinin guclu bir ilk tercih olusturdugunu gostermektedir.

Gelecek calismalar icin: (i) zaman serisine ozellesmis modellerin (LSTM, Temporal Fusion Transformer) ayni setrik uzerinde denenmesi, (ii) sektor-ozgu alt modellerin egitilmesi, (iii) makroekonomik gostergelerin (faiz, enflasyon, GSYH buyumesi) ek ozellik olarak dahil edilmesi ve (iv) daha uzun bir zaman penceresi (1990-2024) ile modelin robustlugunun dogrulanmasi onerilmektedir.

KAYNAKCA

[1] F. Pedregosa, G. Varoquaux, A. Gramfort, *et al.*, "Scikit-learn: Machine Learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825-2830, 2011.

[2] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5-32, 2001.

[3] J. H. Friedman, "Greedy Function Approximation: A Gradient Boosting Machine," *Annals of Statistics*, vol. 29, no. 5, pp. 1189-1232, 2001.

[4] I. T. Jolliffe, *Principal Component Analysis*, 2nd ed. New York: Springer, 2002.

[5] A. E. Hoerl and R. W. Kennard, "Ridge Regression: Biased Estimation for Nonorthogonal Problems," *Technometrics*, vol. 12, no. 1, pp. 55-67, 1970.

[6] R. Tibshirani, "Regression Shrinkage and Selection via the Lasso," *J. Royal Statistical Society B*, vol. 58, no. 1, pp. 267-288, 1996.

[7] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning*, 2nd ed. New York: Springer, 2009.

[8] "200+ Financial Indicators of US stocks (2014-2018)," *Kaggle Dataset*. [Online]. Available: https://www.kaggle.com/datasets/cnic92/200-financial-indicators-of-us-stocks-20142018

[9] W. McKinney, "Data Structures for Statistical Computing in Python," in *Proc. 9th Python in Science Conf. (SciPy)*, Austin, TX, USA, 2010, pp. 51-56.

[10] J. D. Hunter, "Matplotlib: A 2D Graphics Environment," *Computing in Science & Engineering*, vol. 9, no. 3, pp. 90-95, 2007.